

SliceGAN con discriminadores Vision Transformer y segmentación con SAM

Vision Transformers — FIUBA. Trabajo individual.

1. Objetivo del proyecto

Las microestructuras tridimensionales son necesarias para calcular propiedades efectivas de materiales (por ejemplo, como elementos de volumen representativos para análisis por elementos finitos), pero la adquisición 3D (micro-CT, FIB-SEM) es costosa y a menudo no está disponible, mientras que las micrografías 2D son baratas, rápidas y en general de mayor resolución. Este proyecto genera microestructuras 3D de dos fases a partir de una única micrografía 2D con SliceGAN y estudia si los Vision Transformers la mejoran, ya sea como crítico adversarial o como etapa previa de segmentación.

1.1 Antecedentes: SliceGAN


El problema. Una micrografía 2D de un material contiene, estadísticamente, buena parte de la información de su estructura 3D: en un material *isótropo* (sin dirección preferencial), todo corte plano del volumen tiene la misma estadística (fracciones de fase, tamaños y formas de los rasgos, correlaciones espaciales) que cualquier otro. La tarea es entonces producir volúmenes 3D cuyas secciones 2D sean estadísticamente indistinguibles de la micrografía. Los métodos clásicos de reconstrucción optimizan un volumen 3D para ajustar descriptores estadísticos elegidos (por ejemplo, la correlación de dos puntos); son lentos (horas para 10^6 vóxeles) y solo reproducen los descriptores que se les pidió ajustar.

Redes generativas adversariales. Una GAN entrena dos redes enfrentadas: un *generador* G que transforma ruido aleatorio en muestras, y un *discriminador* (crítico) D que intenta distinguir las muestras generadas de las reales. G se actualiza para engañar a D; en el equilibrio, la distribución generada coincide con la real. Las GAN aprenden la estadística directamente de los datos en lugar de descriptores elegidos a mano y, una vez entrenadas, generan muestras nuevas en segundos.

La idea clave de SliceGAN: expansión de dimensionalidad mediante cortes (Kench & Cooper, 2021). Normalmente una GAN necesita datos de entrenamiento con la misma dimensionalidad que su salida, pero aquí no hay datos 3D. SliceGAN combina un **generador 3D** con un **discriminador 2D** y los conecta mediante un paso de corte:

1. G transforma un tensor latente z (ruido gaussiano de forma $32 \times 4 \times 4 \times 4$ en este proyecto) en un volumen de 64^3 con un canal por fase (softmax, es decir, una codificación one-hot suave).
2. El volumen generado se corta en sus 64 rebanadas a lo largo de cada uno de los tres ejes ($3 \times 64 = 192$ rebanadas).
3. D, una red convolucional 2D, puntúa cada rebanada y un recorte aleatorio del mismo tamaño de la micrografía real. Para un material isótropo, un único D sirve para las tres direcciones.
4. Se combinan las pérdidas de todas las rebanadas y se actualizan ambas redes. Como cada rebanada del volumen debe parecerse a la micrografía, G aprende una estructura 3D cuyas secciones en x , y y z reproducen la estadística 2D.

SliceGAN: a 3D generator trained against a 2D critic through slicing



Entrenamiento de SliceGAN

El entrenamiento usa la pérdida de Wasserstein con penalización de gradiente (WGAN-GP; Gulrajani et al., 2017), en la que D es un *crítico* no acotado que estima la distancia de Wasserstein entre rebanadas reales y generadas, con 5 actualizaciones del crítico por cada actualización del generador. El Algoritmo 1 del artículo le muestra a D las 64 rebanadas por dirección de cada volumen generado y usa un lote del generador del doble del lote del crítico ($m_G = 2 m_D$), configuración que los autores encontraron más eficiente.

Diseño del generador: densidad de información uniforme. Las primeras versiones de SliceGAN producían peor calidad cerca de los bordes del volumen. La causa es la convolución transpuesta: un vóxel cerca del borde de la salida recibe contribuciones de menos posiciones del kernel que uno central, de modo que la información queda distribuida de forma desigual. En microestructuras, donde los bordes importan tanto como el centro, los autores derivan reglas para el tamaño de kernel k , el paso s y el relleno p ($s < k, k \bmod s = 0, p \geq k - s$) y usan $\{k, s, p\} = \{4, 2, 2\}$. Además, dan al latente z un tamaño espacial de 4 en lugar de 1, de modo que la primera capa ya aprende salidas de kernel superpuestas; como consecuencia, se pueden generar volúmenes mayores que 64^3 después del entrenamiento simplemente agrandando z . El código publicado (usado aquí sin cambios) reemplaza la última convolución transpuesta por un sobremuestreo + convolución ("resize-convolution") para evitar artefactos de tablero de ajedrez. El crítico es una CNN 2D simple de cinco convoluciones con paso (rebanada de $64 \times 64 \rightarrow$ un puntaje).

Alcance y límites. SliceGAN reproduce la estadística de la micrografía sin descriptores elegidos a mano, entrena en pocas horas en una GPU y genera volúmenes en segundos. Fue validado contra datos 3D reales de un electrodo de batería y luego aplicado a 87 materiales de la biblioteca MicroLib (Kench et al., 2022). Sus supuestos principales son la isotropía (los materiales anisótropos necesitan dos o tres micrografías perpendiculares y críticos separados) y un campo de visión representativo del material.

1.2 Antecedentes: Swin-T y SAM, y dónde entran en el pipeline

Swin Transformer (Swin-T; Liu et al., 2021) es un Vision Transformer jerárquico:

- la imagen se divide en parches de 4×4 , cada uno embebido como un token;
- la autoatención se calcula dentro de ventanas locales de 7×7 tokens, que se desplazan entre capas consecutivas para que la información también fluya entre ventanas;
- cuatro etapas fusionan parches entre ellas, lo que da mapas de características de resolución decreciente (como una CNN);
- la posición se codifica con un sesgo de posición relativa dentro de cada ventana, no con embeddings absolutos, por lo que la red también funciona sobre rebanadas pequeñas de 64×64 ;

- Swin-T tiene 28 M de parámetros y está preentrenado en ImageNet-1k.


En este proyecto Swin-T reemplaza (M2, M3) o complementa (M4, M5) a la CNN de SliceGAN como crítico 2D, aportando características preentrenadas y atención sobre toda la rebanada. Se sabe que los críticos Transformer desestabilizan el entrenamiento de GANs (ViTGAN; Lee et al., 2022), y esa resultó ser la dificultad central (Sección 5.2).

Segment Anything (SAM; Kirillov et al., 2023) es un modelo de segmentación guiado por prompts: un codificador de imagen ViT, un codificador de prompts (puntos, cajas) y un decodificador de máscaras liviano, entrenado con mil millones de máscaras. En modo automático, una grilla de puntos produce una máscara por cada objeto, sin entrenamiento adicional (zero-shot).

Cómo se incluye SAM. SliceGAN necesita una micrografía segmentada (una etiqueta por fase) como dato de entrenamiento; la línea base la obtiene con un umbral global de nivel de gris (Otsu). SAM se usa como *etapa previa* alternativa para este paso de segmentación, y el resto del pipeline no cambia:

1. SAM ViT-B ([facebook/sam-vit-base](https://github.com/facebook/sam), sin ajuste fino) se ejecuta sobre teselas superpuestas de 256 px de la micrografía con una grilla de 32×32 puntos por tesela (una sola pasada sobre la imagen completa pierde la mayoría de las islas pequeñas);
2. las máscaras superpuestas (IoU > 0,3) se fusionan;
3. cada grupo fusionado se etiqueta como inclusión o matriz según su nivel de gris medio (una división en dos clases de las medias de los grupos; los píxeles no cubiertos son matriz);
4. el mapa de fases resultante reemplaza al mapa de Otsu como imagen de entrenamiento del modelo M3.

Phase segmentation of MicroLib 000210 (crop): Otsu ($\varphi = 0.232$) vs SAM ($\varphi = 0.217$)




Segmentación con SAM

1.3 Preguntas de investigación

- **PI1 — crítico ViT.** ¿Reemplazar el discriminador CNN de SliceGAN por un Swin Transformer (Swin-T) mejora las microestructuras generadas? (M1 vs M2, con una ablación M1 + DiffAug)
- **PI2 — segmentación con SAM.** ¿Segmentar la micrografía con SAM, en lugar de un umbral global, las mejora? (M2 vs M3)
- **PI3 — ViT como crítico adicional (extensión).** ¿Agregar un crítico Swin-T preentrenado junto a la CNN de SliceGAN, como en Vision-aided GAN (Kumari et al., 2022), ayuda, ya sea desde cero (M4) o como etapa de ajuste fino de un SliceGAN ya entrenado (M5, comparado contra M1 entrenado los mismos pasos extra)?

La calidad se mide con los descriptores estadísticos usados en la literatura de generación de microestructuras (fracción de fase, correlación de dos puntos, camino lineal), ya que no existe una referencia 3D.

2. Arquitectura general



Pipeline

Datos. El caso principal es la entrada 000210 de MicroLib (biblioteca de micrografías DoITPoMS): una micrografía óptica de islas oscuras en una matriz clara, de 437×800 px tras quitar la barra de escala, $0,687 \mu\text{m}/\text{px}$. Se eligió al azar entre las entradas de dos fases de MicroLib con una diferencia de nivel de gris entre fases ≥ 80 y se aceptó tras un control de isotropía (cociente de longitudes de correlación x/y de 1,11). Una micrografía sintética (discos sin superposición, $\phi = 0,25$, renderizada con desenfoque y ruido, con máscara de referencia exacta) se usa como control.

Segmentación (etapa previa). M1, M2, M4 y M5 entrenan sobre un mapa de etiquetas de Otsu ($\phi = 0,232$). M3 entrena sobre un mapa de SAM: SAM ViT-B zero-shot sobre teselas de 256 px, máscaras superpuestas fusionadas ($\text{IoU} > 0,3$) y grupos cuyo gris medio se aparta del de la matriz etiquetados como inclusiones ($\phi = 0,217$).

Generador. El generador 3D de SliceGAN con resize-convolution, sin cambios en todos los modelos (40,1 M de parámetros): latente gaussiano de $32 \times 4 \times 4 \times 4 \rightarrow$ volumen de 64^3 , softmax sobre las dos fases.

Cortador y críticos. Cada volumen generado se corta en sus 64 rebanadas en x, y y z. Las rebanadas y recortes reales de 64×64 de la imagen de entrenamiento se puntúan con un crítico 2D:

Modelo	Imagen de entrenamiento	Crítico 2D	Pérdida	Parámetros entrenables del crítico
M1	Otsu	CNN de SliceGAN (5 convoluciones con paso)	WGAN-GP	2,8 M
M2	Otsu	Swin-T (ImageNet), etapas 3–4 + cabeza entrenables, DiffAug, lr 2e-5	WGAN-GP	26,3 M
M3	SAM	mismo crítico que M2	igual que M2	igual que M2
M4	Otsu	CNN de SliceGAN + Swin-T congelado con cabezas por escala (ensamble)	CNN: WGAN-GP, Swin: hinge	2,8 M + 0,18 M
M5	Otsu	como M4, generador inicializado desde el mejor checkpoint de M1	como M4	como M4
M1-ext	Otsu	como M1, generador inicializado desde el mejor checkpoint de M1	WGAN-GP	2,8 M

Métricas. Para cada modelo, 128 volúmenes de 64^3 (semillas 0–127) se comparan con la imagen 2D mediante φ , $S_2(r)$ y $L(r)$, en total y por orientación de corte, con intervalos de confianza bootstrap (Sección 4).

3. Implementación técnica

Stack. Python 3.11, PyTorch 2.5.1 (CUDA 12.4), timm 1.0.11, Hugging Face `transformers` 4.46.3, NumPy/SciPy/scikit-image, entorno Poetry (`setup.sh`), configuraciones YAML con herencia y superposición por dataset, logging a archivo y consola, seguimiento de experimentos con MLflow, 81 tests de pytest. Entrenado en una NVIDIA RTX A2000 (12 GB).

Modelos preentrenados.

- Swin-T: `timmm/swin_tiny_patch4_window7_224.ms_in1k` en el Hugging Face Hub (el checkpoint ImageNet-1k de Microsoft, con los mismos pesos que `microsoft/swin-tiny-patch4-window7-224`). Se usa timm en lugar de `transformers` porque Swin-T solo funciona de forma nativa sobre rebanadas de 64 px si las ventanas de atención de las etapas 3–4 se reducen a 4×4 y 2×2 con un sesgo de posición relativa redimensionado, algo que timm soporta y `transformers` 4.46 no. El embedding de parches RGB se

convierte a dos canales de fase, de modo que una rebanada one-hot se ve como una imagen de grises centrada (matriz $-0,5$, inclusión $+0,5$).

- SAM: `facebook/sam-vit-base` a través del pipeline de generación de máscaras de `transformers`, zero-shot.

Integración de SliceGAN. El repositorio original es un submódulo de git (`external/SliceGAN`, MIT) y no se modifica. `src/models/slicegan_wrapper.py` construye el generador y el crítico CNN con la fábrica de redes original y las listas de capas exactas de `run_slicegan.py`, y reutiliza su penalización de gradiente. `src/models/train.py` es una bifurcación del bucle de entrenamiento original con el mismo esquema WGAN-GP (Adam $1e-4$, $\beta = (0,9, 0,99)$, $\lambda_{GP} = 10$, 5 pasos del crítico por paso del generador) y la regla de lotes del Algoritmo 1 de SliceGAN: el crítico ve las 64 rebanadas por eje de $m_D = 1$ volumen y el paso del generador usa $m_G = 2 m_D$ volúmenes. Agregados: ramas de crítico (crítico único o ensamble CNN + Swin), pérdida hinge, aumentación diferenciable de las entradas del crítico (DiffAug: traslación, cutout, rotaciones de 90° y reflexiones), arranque en caliente del generador y selección de checkpoints.

Selección de checkpoints y protocolo de evaluación. Después de cada época (100 pasos del generador), el generador produce 16 volúmenes con semillas reservadas (1000–1015), y se conserva la época con menor S_2 MAE respecto de la imagen de entrenamiento del propio modelo. El checkpoint conservado se evalúa luego sobre 128 semillas *distintas* (0–127), de modo que los números reportados nunca se miden sobre los volúmenes usados para elegir el checkpoint. La misma regla se aplica a todos los modelos. El protocolo se endureció dos veces durante el proyecto, porque un volumen de 64^3 es una muestra pequeña de la microestructura (≈ 30 islas; la fracción de fase varía $\pm 0,05$ de un volumen a otro): con 2 semillas de selección y 4 de evaluación (corrida v5), el ranking de modelos se invirtió al reevaluar con 32 semillas, y un checkpoint elegido como el mejor con 2 semillas podía ser tres veces peor que la última época sobre semillas nuevas. Incluso con 16 semillas, elegir la mejor de 50 puntuaciones ruidosas es optimista (la “maldición del ganador”: el checkpoint seleccionado de M1 obtuvo S_2 MAE 0,0016 en sus semillas de selección pero 0,020 en 128 semillas nuevas); evaluar sobre semillas independientes elimina ese sesgo de los números reportados.

Exportación de RVE. `src/models/export_rve.py` escribe las microestructuras generadas para códigos de homogeneización por FEM/FFT (VTK `.vti`, MetaImage `.mhd/.raw`, malla de vóxeles Abaqus `.inp` con conjuntos de elementos por fase y conjuntos de nodos por cara, NumPy, TIFF, más metadatos JSON). Los volúmenes mayores que 64^3 se obtienen agrandando el latente de entrada; los RVE periódicos usan el mosaico del latente de SliceGAN con un recorte de 2 vóxeles, que resultó ser el período correcto (el recorte de 1 vóxel del código original duplica una rebanada en la costura); la periodicidad se verifica comparando la discrepancia entre caras opuestas con la discrepancia entre rebanadas interiores vecinas (cociente 1,0–2,0 frente a 8–13 sin mosaico).

Módulos principales. `src/data/make_dataset.py` (descarga, recorte, Otsu, recortes), `src/features/sam_segment.py` (segmentación con SAM), `src/features/descriptors.py` (ϕ , S_2 , L), `src/models/discriminator_swin.py` (críticos Swin), `src/models/train.py`, `src/models/generate.py` (volúmenes + métricas), `src/visualization/visualize.py` (figuras, `metrics.csv`), un visor interactivo de volúmenes (`reports/viewer/`) y el notebook de análisis exploratorio `notebooks/00_edu.ipynb`.

4. Evaluación

No existe una referencia 3D (no hay micro-CT), así que los volúmenes generados se comparan estadísticamente con la imagen 2D de entrenamiento. En un material isótropo, cualquier sección plana de la microestructura 3D tiene la misma estadística que la micrografía 2D, por lo que los descriptores 2D de la imagen de entrenamiento deben coincidir con los descriptores promediados sobre las rebanadas del volumen generado; esa es la justificación de las métricas siguientes (SliceGAN, Kench & Cooper 2021). Todas están implementadas en

src/features/descriptors.py y probadas en tests/test_descriptors.py contra casos con solución analítica. La etiqueta 1 es la fase inclusión/poro e $I(x)$ su función indicadora; las curvas se evalúan para $r = 0 \dots 32$ px sobre $N = 128$ volúmenes generados de 64^3 por modelo (semillas distintas; la consigna exige $N \geq 4$).

- **Fracción de fase** $\phi = \langle I(x) \rangle$, reportada como media $\pm$ desvío sobre los N volúmenes, junto con $|\Delta\phi| = |\phi_{\text{gen}} - \phi_{\text{train}}|$.
- **Correlación de dos puntos** $S_2(r) = P[I(x) = 1, I(x + r) = 1]$, calculada por autocorrelación vía FFT (cada desplazamiento normalizado por su número de pares de píxeles válidos, sin suponer periodicidad) y promediada radialmente sobre los vectores con $\text{round}(|r|) = r$. $S_2(0) = \phi$ y $S_2(r) \rightarrow \phi^2$ para puntos no correlacionados. En un volumen, S_2 se promedia sobre todas las rebanadas xy, xz e yz (192 rebanadas para 64^3).
- **Camino lineal** $L(r)$ (como en Micro3Diff, Lee & Yun 2024; Lyu & Ren 2024): probabilidad de que un segmento recto de $r + 1$ píxeles quede completamente en la fase inclusión, promediada sobre ambas direcciones del plano (2D) o los tres ejes (3D). $L(0) = \phi$; a diferencia de S_2 , L es sensible a la conectividad a lo largo de líneas.
- **Errores**: MAE sobre r entre las curvas generadas y de entrenamiento (S_2 MAE, L MAE, usando la curva media sobre los N volúmenes) y la tasa de error de Micro3Diff $\text{err}(S_2) = \text{mean}|S_2_{\text{gen}} - S_2_{\text{train}}| / \text{mean}|S_2_{\text{train}}|$ (análogamente $\text{err}(L)$).
- **Control de isotropía 3D**: ϕ , S_2 MAE y L MAE por orientación de corte (xy, xz, yz). Si un plano diverge, el volumen no es isotrópico. Promediando sobre todas las rebanadas, $\phi_{xy} = \phi_{xz} = \phi_{yz} = \phi$ por construcción, por lo que también se reporta la dispersión de la ϕ por rebanada a lo largo de cada eje.
- **Incertidumbre**. Los intervalos de confianza del 95 % para $|\Delta\phi|$, S_2 MAE y L MAE provienen de un bootstrap sobre los 128 volúmenes (2000 remuestreos, cada uno recalculando la métrica exactamente como se reporta). Cada modelo se compara con la línea base M1 mediante la distribución bootstrap de la diferencia; un modelo se declara mejor o peor solo si ese intervalo excluye el cero.
- **Calidad típica durante el entrenamiento (sin selección)**. Las puntuaciones reservadas por época son insesgadas individualmente; solo elegir su mínimo es optimista. La mediana y el rango intercuartílico del S_2 MAE reservado por época en la segunda mitad del entrenamiento, y el número de épocas colapsadas (ϕ reservada $< 0,05$), resumen cuán bueno y cuán estable es un modelo sin ninguna selección.
- **Referencia común**. Cada modelo se evalúa contra su propia imagen de entrenamiento y contra una referencia compartida por todos los modelos de un dataset, para que M3 (entrenado sobre el mapa de SAM) sea comparable con M2: el mapa de Otsu para MicroLib (no existe referencia exacta) y la máscara exacta para los datos sintéticos.
- **Calidad de la segmentación de SAM** (etapa previa de M3): $\text{IoU} = |P \cap G| / |P \cup G|$ y $\text{Dice} = 2|P \cap G| / (|P| + |G|)$ del mapa de etiquetas P contra la referencia exacta G en la imagen sintética y, en MicroLib, contra una referencia curada: el punto medio de los dos niveles de gris de fase anotados por los autores de MicroLib (8 y 133) aplicado a la micrografía original.

Escalas de referencia: en el dataset sintético, la segmentación de Otsu frente a la máscara exacta da S_2 MAE = 0,0021. Volúmenes aleatorios no correlacionados de 64^3 con la ϕ correcta de MicroLib 000210 dan S_2 MAE = 0,042 ($\text{err} = 0,42$) y L MAE = 0,077 ($\text{err} = 0,89$), un piso que cualquier modelo útil debe superar.

No se usan FID ni SSIM 3D (requieren una referencia volumétrica), y no se reporta exactitud de clasificación.

5. Resultados y ejemplos

5.1 Resultados principales (MicroLib 000210)


Protocolo entrenamiento / validación / prueba (Sección 3): el checkpoint de cada modelo se elige entre el mejor por época, la última época y las instantáneas de entrenamiento sobre 128 semillas de validación, y luego

se evalúa sobre 128 volúmenes de prueba contra la referencia común (mapa de Otsu, $\phi = 0,232$). Entre corchetes: intervalos bootstrap del 95 %. “Típico” es la mediana sin selección del S_2 MAE reservado en la segunda mitad del entrenamiento (16 semillas por época, por lo que está en otra escala que las columnas de prueba).


Modelo	Checkpoint	ϕ	$ \Delta\phi $	S_2 MAE	L MAE	S_2 típico	vs M1
M1 CNN (SliceGAN)	última	0,235	0,003 [0,000, 0,012]	0,0029 [0,0008, 0,0087]	0,0011 [0,0003, 0,0059]	0,0051	—
M1 + DiffAug	última	0,229	0,003 [0,000, 0,012]	0,0009 [0,0006, 0,0066]	0,0014 [0,0010, 0,0059]	0,0136	sin diferencia clara
M2 Swin + DiffAug	mejor	0,239	0,007 [0,000, 0,017]	0,0077 [0,0017, 0,0141]	0,0055 [0,0010, 0,0109]	0,0132	sin diferencia clara
M3 Swin + DiffAug, mapa SAM	última	0,174	0,058 [0,050, 0,066]	0,0328 [0,0281, 0,0371]	0,0262 [0,0223, 0,0299]	0,0143	peor (todas las métricas)
M4 CNN + Swin congelado	mejor (= última)	0,232	0,000 [0,000, 0,009]	0,0014 [0,0006, 0,0067]	0,0015 [0,0006, 0,0058]	0,0096	sin diferencia clara
M5 M1 + ajuste fino con Swin	última	0,243	0,010 [0,001, 0,020]	0,0097 [0,0033, 0,0161]	0,0092 [0,0038, 0,0147]	0,0072	peor en L
M1 extendido	última	0,238	0,006 [0,000, 0,015]	0,0059 [0,0010, 0,0124]	0,0059 [0,0019, 0,0114]	0,0097	sin diferencia clara

Todos los errores están muy por debajo del piso de volúmenes aleatorios (S_2 MAE 0,042, L MAE 0,077). Los modelos basados en CNN (M1, M1 + DiffAug, M4) forman el mejor grupo: sus estimaciones puntuales son las más bajas y sus intervalos se superponen. M4, el ensamble CNN + Swin congelado, reproduce exactamente la fracción de fase (0,232) y no necesitó selección de checkpoint (su mejor época es la última). Ningún modelo es significativamente mejor que M1 con 128 volúmenes de prueba; M3 es significativamente peor, porque su imagen de entrenamiento (el mapa de SAM) tiene menor fracción de fase y distinta morfología que la referencia de Otsu, y su último checkpoint subestima ϕ aún más.

microlib_000210: generated 64³ volumes (mean over slices and seeds) vs 2D Otsu label map



Curvas de descriptores



Comparación cualitativa


Curvas de entrenamiento por modelo: [figures/microlib_000210_training.png](#); todos los volúmenes pueden explorarse en el visor interactivo ([reports/viewer/](#)).

5.2 Entrenar un crítico Swin: estudio de estabilización

Se sabe que los críticos Transformer vuelven inestable el entrenamiento de GANs (ViTGAN, Lee et al., 2022). Con la configuración WGAN-GP de SliceGAN, el crítico Swin-T fue inestable en todas las configuraciones probadas; la tabla resume las primeras 12 épocas en MicroLib (objetivo de φ reservada 0,232; S_2 MAE de las mejores épocas de M1: 0,002–0,004).

Corrida	Crítico Swin	Pérdida	DiffAug	Épocas 1–12	Resultado
v1	etapas 3–4 entrenables, lr 1e-4, último checkpoint	WGAN-GP	no	realista en la época 10, vacío en la 15	oscila, terminó colapsado (φ = 0,003)
v2	etapas 3–4, lr 2e-5	WGAN-GP	no	vacío en 4–5, S_2 MAE 0,010 en 9–11	oscila, existen épocas al nivel de M1
v2 repetida	misma configuración y semilla	WGAN-GP	no	buena en la época 2, luego $\varphi \approx 0$ durante 10 épocas	variabilidad entre corridas: kernels de GPU no deterministas, amplificadas por la dinámica de la GAN
v3	v2 + ViTGAN: spectral norm mejorada, Adam β_1 = 0, EMA de G	WGAN-GP	no	φ 0,002–0,08 en todo momento	crítico demasiado fuerte
sonda etapa 4	solo la etapa 4 entrenable	WGAN-GP	no	φ 0,08–0,29, mejor S_2 MAE 0,037	sin colapso total, borroso
A	congelado, cabeza multiescala con pooling	WGAN-GP	sí	φ = 1,0 en las épocas 1–6, luego 0,51 $\rightarrow$ 0,31; mejor S_2 MAE 0,049	falla: la penalización de gradiente no puede cumplirse a través de un backbone congelado
B	etapas 3–4, lr 2e-5	WGAN-GP	sí	$\varphi \approx 0$ en las épocas 1–5; desde la 7, φ 0,20–0,30, S_2 MAE 0,0091 / 0,018 / 0,0035 / 0,024 / 0,049 / 0,0035	aprueba: épocas al nivel de M1, más consistente que v2
C	congelado, cabezas multiescala por posición	WGAN-GP	sí	φ = 1,0 en las épocas 1–2, 0,89–0,95 hasta la 8, luego 0,38 $\rightarrow$ 0,08 $\rightarrow$ 0,11; mejor S_2 MAE 0,060	falla como A: el problema es la GP, no el pooling
A-hinge	congelado, cabeza con pooling, spectral norm en la cabeza	hinge	sí	φ 0,57–1,0, en aumento; mejor S_2 MAE 0,26	falla: sin colapso, pero φ sin control
C-hinge	congelado, cabezas por posición, spectral norm en la cabeza	hinge	sí	φ 0,31–0,56; mejor S_2 MAE 0,12	falla solo; mejor que A-hinge, usado dentro de M4/M5

Swin critic probes on MicroLib 000210: held-out ϕ and S_2 MAE per epoch (first 12 epochs)



Sondas del crítico Swin

Los registros por época de cada sonda están en [reports/probes/](#).

Decisión. M2/M3 usan la sonda B (el único crítico solo-Swin que alcanza épocas al nivel de M1); M4/M5 usan las cabezas congeladas por posición de C-hinge dentro de un ensamble con el crítico CNN.


Tres hallazgos dieron forma a los modelos finales. Primero, un backbone preentrenado congelado no puede entrenarse con WGAN-GP: la penalización de gradiente exige norma unitaria del gradiente respecto de la entrada, que las capas Swin congeladas fijan y la pequeña cabeza solo puede reescalar, de modo que la penalización domina (valores de 10–355 en lugar de ≈ 1) y el crítico no da una señal útil. Los críticos con backbone congelado de la literatura (Projected GAN, Vision-aided GAN) usan pérdidas hinge o BCE. Segundo, Vision-aided GAN reporta que los críticos preentrenados usados *solos* divergen y solo ayudan en un ensamble con el discriminador original, lo que motiva M4 y M5. Tercero, con pérdida hinge el crítico Swin congelado ya no colapsa, pero no controla por sí solo la fracción de fase (ϕ deriva a 0,3–0,8); una causa plausible es la LayerNorm por token de Swin, que elimina buena parte de la información de intensidad absoluta de la fase. El crítico CNN de M4/M5 aporta esa restricción. Por último, DiffAug es lo que hizo funcionar al crítico Swin entrenable (B vs v2), en línea con la literatura de GANs con pocos datos (Zhao et al., 2020; Karras et al., 2020): de otro modo, el crítico sobreajusta las pocas centenas de vistas distintas de una única micrografía.

Diagnóstico con sonda lineal (Vision-aided GAN, Sec. 3.2): una regresión logística sobre características Swin congeladas y con pooling separa recortes reales de 64×64 de rebanadas del mejor generador de M1 con 73 % de exactitud reservada a 64 px de entrada (solo la etapa 2: 75 %), 83 % a 128 px y 83 % a 224 px; los volúmenes aleatorios con la ϕ correcta se separan al 100 %. Las características congeladas contienen entonces una señal real-vs-falso utilizable, más fuerte a la resolución 8×8 de la etapa 2, y una entrada más grande podría sumar unos 10 puntos.

5.3 Ajuste fino con un crítico Swin (M5 vs M1 extendido)

Ambas corridas parten del checkpoint seleccionado de M1 y entrenan 20 épocas más con críticos nuevos; solo difieren en los críticos (CNN vs CNN + Swin congelado con cabezas por posición). Ninguna mejora a M1: en los volúmenes de prueba, M1 extendido alcanza S_2 MAE 0,0059 y M5 0,0097 (M1: 0,0029), y sus mejores puntuaciones reservadas por época se alcanzaron en la primera época, es decir, en el punto de partida. Una vez que SliceGAN convergió, agregar el crítico Swin como etapa de ajuste fino (la receta de Vision-aided GAN) no ayuda en este caso. Una versión anterior de esta comparación (corrida v5, selección con 2 semillas) sugería lo contrario; ese resultado era ruido de selección y desapareció con más semillas (Sección 3). En el dataset sintético (Sección 5.6) ambas corridas mejoran a M1 y M5 tiene el menor S_2 MAE de todos los modelos (0,0013

frente a 0,0020 de M1 extendido), pero la diferencia entre ellas no es significativa (intervalo del 95 % de M5 – M1 extendido: $-0,0028$ a $+0,0023$): la mejora proviene del entrenamiento adicional, no del crítico Swin.



M5 vs M1 extendido (trazas de selección de la corrida v5)

5.4 Segmentación con SAM

Dataset	ϕ SAM	ϕ Otsu	Referencia (ϕ)	IoU / Dice SAM	IoU / Dice Otsu
sintético	0,290	0,254	máscara exacta (0,250)	0,864 / 0,927	0,913 / 0,955
MicroLib 000210	0,217	0,232	umbral anotado de MicroLib (0,219)	0,845 / 0,916	0,941 / 0,970

SAM zero-shot necesita teselado en esta imagen (una sola pasada con 16 puntos por lado encuentra $\phi = 0,07$), e incluso con teselado tiene menor IoU/Dice que Otsu frente a ambas referencias. El notebook exploratorio ([notebooks/00_edu.ipynb](#)) muestra de dónde vienen los errores:


- **Sintético (referencia exacta):** el error de SAM es una dilatación sistemática de un píxel. Todos sus píxeles erróneos están a menos de 2 px de una interfaz real y casi todos son falsas inclusiones, lo que suma una sobreestimación de ϕ del 16 %. Los errores de Otsu están en las mismas interfaces pero se compensan, por lo que su ϕ es casi exacta.
- **MicroLib:** ambos mapas coinciden en el 96 % de los píxeles. Dos tercios de la discrepancia son el halo gris alrededor de cada partícula oscura, que Otsu (umbral 79, por encima del punto medio curado 70) etiqueta como inclusión. El resto son algunas regiones de gris intermedio que SAM toma como objetos completos. En consecuencia, la ϕ , S_2 y L de SAM están *más cerca* de la referencia curada que las de Otsu (S_2 MAE 0,0009 vs 0,0085). Aun así, Otsu tiene mayor IoU, porque la referencia es en sí misma un umbral global y favorece estructuralmente a Otsu.

Por lo tanto, la elección de la etapa de segmentación desplaza el *objetivo* de la GAN en unos 0,009 de S_2 MAE, más que la diferencia entre los mejores modelos de MicroLib (0,001–0,003). Por eso cada modelo se evalúa contra su propio mapa de entrenamiento y, por separado, contra una referencia común (§4).

El análisis exploratorio también muestra que la micrografía tiene un leve bandeo en x: la longitud de correlación es de unos 23 px en x frente a 19 px en y (S_2 dentro del 5 % de su meseta). SliceGAN supone la misma estadística en los tres planos, y la aumentación D4 de los recortes simetriza x e y a propósito, de modo que los generadores aprenden una versión isótropa de la estructura. Las métricas con promedio radial son insensibles a esto, pero ningún modelo reproduce aquí la dirección del bandeo.

5.5 ¿Qué miran los críticos?

Saliencia SmoothGrad (Smilkov et al., 2017): el gradiente del puntaje de cada crítico entrenado respecto de su entrada one-hot, promediado sobre 16 copias con ruido, en 32 recortes reales y 32 rebanadas generadas (`src/visualization/critic_saliency.py`, valores en `reports/critic_saliency.json`).



Saliencia de los críticos

Crítico	Saliencia sobre bordes de fase (la banda de borde = 12 % de los píxeles)	P(puntaje real > puntaje generado)
M1 CNN de SliceGAN	25 % (2,1 × su área)	0,75
M2 Swin-T, etapas 3–4 entrenadas	22 % (1,8 ×)	0,79
M4 Swin-T congelado, cabezas por posición	16 % (1,3 ×)	0,67


El crítico CNN se concentra en los contornos de las inclusiones: juzga interfaces. El Swin-T entrenado también favorece los bordes, pero de forma más difusa, y su saliencia muestra la grilla de parches de 4×4 del transformer. Las cabezas del Swin-T congelado reparten su atención sobre toda la rebanada: responden a la textura y la disposición global más que a los bordes locales, y son las que peor separan, por sí solas, rebanadas reales de generadas. Los dos críticos de M4 usan, por lo tanto, señales complementarias (CNN: interfaces; Swin congelado: textura global), una razón plausible de que el ensamble sea el modelo más estable, mientras que el Swin congelado solo no puede controlar la fracción de fase (Sección 5.2).

5.6 Dataset sintético: comparación contra una referencia exacta


Los siete modelos se reentrenaron sobre la micrografía sintética con las mismas configuraciones y el mismo protocolo. Aquí la referencia común es la máscara exacta ($\phi = 0,250$), por lo que las puntuaciones miden cuán cerca llega cada modelo a la estructura *verdadera*, incluido el error de su etapa de segmentación. Como escala, el propio mapa de Otsu obtiene S_2 MAE 0,0021 frente a esta máscara.

Modelo	Checkpoint	ϕ	$ \Delta\phi $	S_2 MAE	L MAE	S_2 típico	vs M1
M1 CNN (SliceGAN)	instantánea ép. 30	0,240	0,010 [0,003, 0,017]	0,0040 [0,0023, 0,0080]	0,0052 [0,0042, 0,0066]	0,0084	—
M1 + DiffAug	instantánea ép. 20	0,240	0,010 [0,004, 0,017]	0,0045 [0,0028, 0,0080]	0,0056 [0,0043, 0,0072]	0,0074	sin diferencia clara
M2 Swin + DiffAug	mejor (ép. 29)	0,246	0,004 [0,000, 0,013]	0,0093 [0,0075, 0,0140]	0,0216 [0,0189, 0,0260]	0,0150	peor (S_2 , L)
M3 Swin + DiffAug, mapa SAM	mejor (ép. 15)	0,289	0,039 [0,032, 0,045]	0,0298 [0,0252, 0,0344]	0,0317 [0,0282, 0,0350]	0,0106	peor (todas las métricas)
M4 CNN + Swin congelado	instantánea ép. 35	0,253	0,002 [0,000, 0,008]	0,0039 [0,0026, 0,0075]	0,0052 [0,0046, 0,0067]	0,0032	sin diferencia clara
M5 M1 + ajuste fino con Swin	mejor (ép. 8 de 20)	0,248	0,002 [0,000, 0,008]	0,0013 [0,0008, 0,0046]	0,0053 [0,0049, 0,0061]	0,0050	sin diferencia clara
M1 extendido	mejor (ép. 8 de 20)	0,249	0,002 [0,000, 0,008]	0,0020 [0,0018, 0,0045]	0,0056 [0,0051, 0,0065]	0,0050	sin diferencia clara

synthetic: generated 64^3 volumes (mean over slices and seeds) vs 2D ground-truth mask



Curvas de descriptores, dataset sintético



Comparación cualitativa, dataset sintético

Los resultados sintéticos confirman las conclusiones de MicroLib y vuelven más nítidas dos de ellas:

- **Swin como único crítico (PI1).** M2 es significativamente peor que M1 en S_2 y L, y también peor que la ablación justa M1 + DiffAug (diferencia en S_2 +0,0048 [+0,0006, +0,0098], en L +0,0161 [+0,0129, +0,0206]). Sus volúmenes pierden la morfología de discos/esferas (inclusiones alargadas y fusionadas en el panel cualitativo). Además son **anisótropos**: las rebanadas xy coinciden bien (S_2 MAE 0,0054), las xz e yz no (0,0134 y 0,0101). El mismo patrón aparece en MicroLib (xy 0,0027 frente a xz 0,0114 e yz 0,0098), mientras que los modelos basados en CNN son isótropos en los datos sintéticos. El crítico Swin, por lo tanto, no impone la consistencia entre las tres familias de rebanadas tan bien como la CNN.
- **Segmentación con SAM (PI2).** M3 reproduce fielmente su propio mapa de entrenamiento (S_2 MAE 0,0029 frente al mapa de SAM, ϕ 0,289 frente a 0,290), así que la GAN funciona; el error proviene por completo de la etapa de segmentación, cuya dilatación de un píxel (Sección 5.4) el generador aprende como un rasgo real. Frente a la estructura verdadera, M3 es el peor modelo y es significativamente peor que M2, su equivalente entrenado con Otsu, en todas las métricas.
- **Swin como crítico adicional (PI3).** M4 está a la par de M1 en todas las métricas, reproduce ϕ con un error de 0,002, es significativamente mejor que M2 (S_2 -0,0054 [-0,0102, -0,0015], L -0,0163 [-0,0207, -0,0134]) y es el modelo más estable durante el entrenamiento: su mediana sin selección del S_2 MAE reservado (0,0032, rango intercuartílico 0,0023-0,0039) es la más baja de los siete, menos de la mitad de la de M1 (0,0084). Como etapa de ajuste fino, M5 da el menor S_2 MAE de prueba (0,0013, por debajo del 0,0021 de la propia segmentación de Otsu, porque el generador suaviza el ruido de la segmentación), pero no se distingue de M1 extendido.

6. Conclusiones y trabajo futuro

Respuestas a las preguntas de investigación (dos datasets, 128 volúmenes de prueba por modelo, intervalos bootstrap):

- **PI1 — Swin-T en lugar del crítico CNN: no.** Entrenado con la configuración WGAN-GP de SliceGAN, un crítico Swin-T fue inestable en todas las configuraciones hasta que se agregó DiffAug. Con DiffAug alcanza épocas al nivel de M1, pero los modelos seleccionados nunca superan a la línea base CNN: sin diferencia clara en MicroLib y S_2 y L significativamente peores en los datos sintéticos (también frente a la ablación M1 + DiffAug), con volúmenes menos isótropos en ambos datasets. Los estabilizadores habituales de ViT-GAN (menor tasa de aprendizaje, spectral norm mejorada, Adam $\beta_1 = 0$, EMA del generador, menor parte entrenable) no eliminaron la inestabilidad; un crítico Swin congelado directamente no puede entrenarse con WGAN-GP (la penalización de gradiente domina) y, con pérdida hinge, no controla ϕ .
- **PI2 — SAM en lugar de un umbral global: no, para este tipo de imagen.** En micrografías de dos fases y alto contraste, SAM zero-shot es una segmentación peor que Otsu frente a una referencia exacta (una dilatación sistemática de un píxel, ϕ +16 %). La GAN reproduce fielmente el mapa de SAM, así que M3 hereda ese sesgo y es significativamente peor que M2 en ambos datasets. La etapa de segmentación desplaza el objetivo de la GAN más que cualquier cambio de crítico: la calidad de la segmentación importa más que la arquitectura del crítico.
- **PI3 — Swin-T como crítico adicional: iguala a la línea base y vuelve el entrenamiento más estable.** El ensamble CNN + Swin congelado (M4, al estilo Vision-aided GAN) está estadísticamente a la par de SliceGAN en ambos datasets, es el que mejor reproduce ϕ (exacta en MicroLib, con error de 0,002 en el sintético), es significativamente mejor que el crítico solo-Swin en los datos sintéticos y tiene el entrenamiento más estable (mejor época = última en MicroLib, puntuaciones sin selección más bajas y concentradas en el sintético). Los mapas de saliencia explican por qué ambos críticos se combinan bien: la CNN juzga interfaces y el Swin congelado, la textura global. Usado como etapa de ajuste fino de un SliceGAN ya convergido (M5), el crítico Swin no mejora respecto de entrenar solo la CNN los mismos pasos adicionales.

En conjunto. El pequeño crítico CNN de SliceGAN es difícil de superar en microestructuras de dos fases de 64^3 . Los Vision Transformers ayudan cuando aportan información sin reemplazar a ese crítico: un Swin-T preentrenado y congelado junto a la CNN da el modelo más estable y mejor calibrado, al costo de una cabeza de 0,18 M de parámetros. Una segunda lección es metodológica: un volumen de 64^3 es una muestra ruidosa ($\varphi \pm 0,05$), y los rankings de modelos obtenidos con pocas semillas se invirtieron al reevaluar. Hicieron falta semillas separadas de selección, validación y prueba, e intervalos bootstrap, para llegar a conclusiones que se sostienen.

Limitaciones. Una sola corrida de entrenamiento por modelo y dataset (el entrenamiento de GANs no es determinista en GPU, y la repetición de v2 mostró variabilidad entre corridas); rebanadas de 64 px, que obligan a reducir las ventanas de Swin-T a 4×4 y 2×2 y usan el backbone lejos de su resolución de preentrenamiento de 224 px; una sola micrografía real, de alto contraste y dos fases, donde un umbral global ya es casi óptimo.

SliceGAN es la línea base de 2021 en la literatura; trabajos de 2024 (Micro3Diff, DDPM-GAN) mejoran descriptores y estabilidad con modelos de difusión, pero están fuera del alcance de un proyecto de un curso de Vision Transformers. La contribución aquí es una evaluación controlada de críticos Swin y de SAM como etapa de segmentación.

Trabajo futuro. Críticos Swin con entradas de 128 px (la sonda lineal gana unos 10 puntos a 128 px); segundas semillas de entrenamiento para cada modelo; micrografías más difíciles (bajo contraste, texturas, tres fases), donde la segmentación por objetos de SAM puede rendir, posiblemente con prompts de puntos o un decodificador de máscaras ajustado; materiales anisótropos (SliceGAN con tres vistas, que además preservaría el bandeado visto en la Sección 5.4); homogeneización de los RVE periódicos exportados (FEM/FFT/FNO) con un estudio de convergencia del tamaño del RVE; y generadores basados en difusión.

Referencias

- S. Kench, S. J. Cooper. Generating three-dimensional structures from a two-dimensional slice with generative adversarial network-based dimensionality expansion. *Nature Machine Intelligence*, 2021.
- S. Kench et al. MicroLib: A library of 3D microstructures generated from 2D micrographs using SliceGAN. *Scientific Data*, 2022.
- Z. Liu et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *ICCV*, 2021.
- A. Dosovitskiy et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR*, 2021.
- A. Kirillov et al. Segment Anything. *ICCV*, 2023.
- I. Gulrajani et al. Improved Training of Wasserstein GANs. *NeurIPS*, 2017.
- K. Lee et al. ViTGAN: Training GANs with Vision Transformers. *ICLR*, 2022.
- N. Kumari, R. Zhang, E. Shechtman, J.-Y. Zhu. Ensembling Off-the-shelf Models for GAN Training. *CVPR*, 2022.
- A. Sauer et al. Projected GANs Converge Faster. *NeurIPS*, 2021.
- S. Zhao et al. Differentiable Augmentation for Data-Efficient GAN Training. *NeurIPS*, 2020.
- D. Smilkov et al. SmoothGrad: removing noise by adding noise. *arXiv:1706.03825*, 2017.
- T. Karras et al. Training Generative Adversarial Networks with Limited Data. *NeurIPS*, 2020.
- K.-H. Lee, G. J. Yun. Multi-plane denoising diffusion-based dimensionality expansion for 2D-to-3D reconstruction of microstructures with harmonized sampling (Micro3Diff). *npj Computational Materials*, 2024. doi:10.1038/s41524-024-01280-z
- J. Phan, M. Sarmad, L. Ruspini, G. Kiss, F. Lindseth. Generating 3D images of material microstructures from a single 2D image: a denoising diffusion approach. *Scientific Reports*, 2024.

- X. Lyu, X. Ren. Microstructure reconstruction of 2D/3D random materials via diffusion-based deep generative models. *Scientific Reports*, 2024.